ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas

Business Intelligence

Práctica 1. Implementación de un proceso ETL y Staging Area con Pentaho Data Integration

Al final de esta práctica usted será capaz de:

- Reconocer los principales componentes de Pentaho Data Integration para implementar procesos ETL.
- Extraer datos desde una fuente externa utilizando Pentaho Data Integration.
- Implementar una Staging Area para preparar los datos antes de su carga.
- Aplicar transformaciones básicas para limpiar y estandarizar los datos.
- Ejecutar un flujo ETL completo siguiendo las etapas Extract → Transform → Load.
- Verificar la calidad y consistencia de los datos obtenidos después del proceso de transformación.
- Relacionar el proceso desarrollado con la arquitectura básica de un Data Warehouse.

✓ Es una herramienta de la suite de Pentaho.

✓ Escrito en Java.

✓ Spoon es el diseñador gráfico de transformaciones y trabajos del sistema de ETLs de Pentaho Data Integration (PDI), también conocido como Kettle (acrónimo recursivo: "Kettle Extraction, Transformation, Transportation, and Load Environment").

✓ Está diseñado para ayudar en los procesos ETLs, que incluyen la Extracción, Transformación, Transporte y Carga de datos.

✓ Spoon es una Interfaz Gráfica de Usuario (GUI), que permite diseñar transformaciones y trabajos que se pueden ejecutar con las herramientas de Kettle (Pan y Kitchen).

✓ PDI facilita la construcción, actualización, y mantenimiento de Data Warehouses.

INSTALACIÓN

1. **Decargar las versiones:**

Pentaho Commnity Edition
pdi-ce-10.2.0.0-222
Java
jdk-18.0.2.1_windows-x64_bin

software

2. **Instalar el JDK**

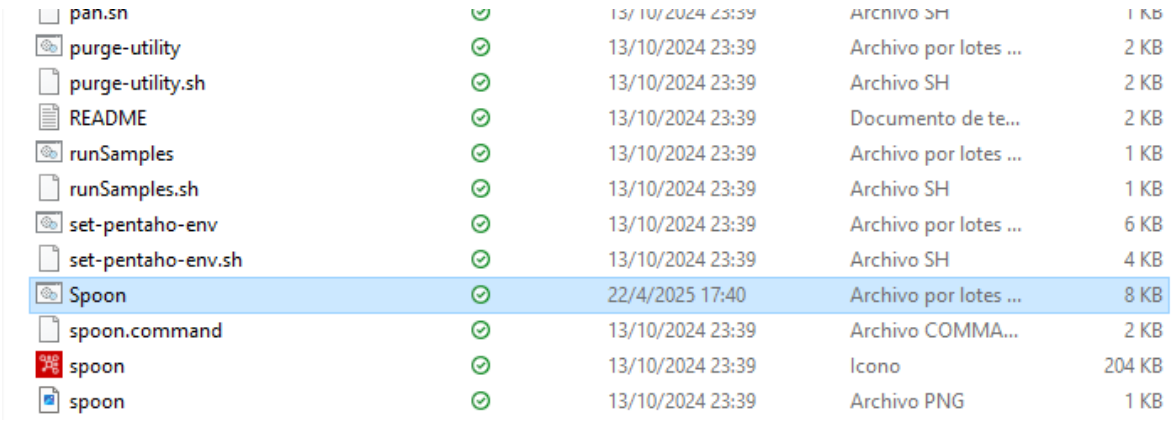
3. **Configurar la variable de entorno JAVA_HOME**

Pentaho necesita que JAVA_HOME apunte correctamente al JDK.

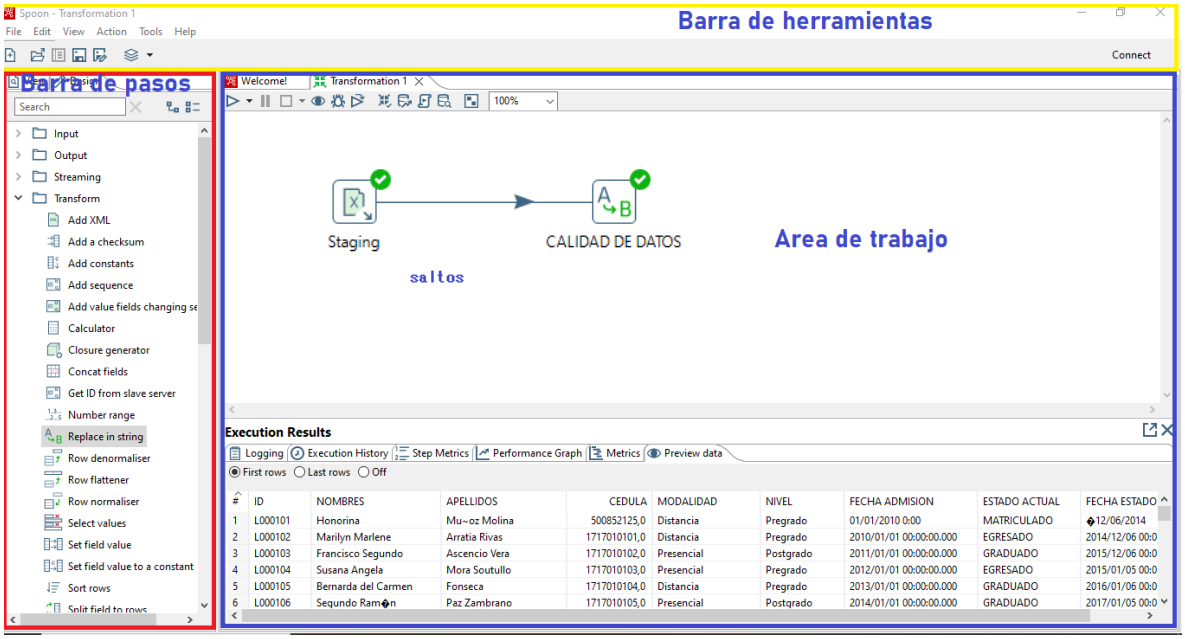
a) Ir a **Panel de control > Sistema > Configuración avanzada del sistema**.
b) Clic en **"Variables de entorno"**.
c) En "Variables del sistema", clic en "Nueva" y crear:
Nombre de la variable: JAVA_HOME
Valor de la variable: la ruta completa al **JDK**, por ejemplo:
C:\Program Files\Java\jdk18.0.2.1

d) Editar la variable **Path** y añadir al final:
%JAVA_HOME%\bin

4. **Dentro de la carpeta de Pentaho, ejecutar como Administrador el archivo Spoon:**



5. **Se deberá abrir la interfaz gráfica:**

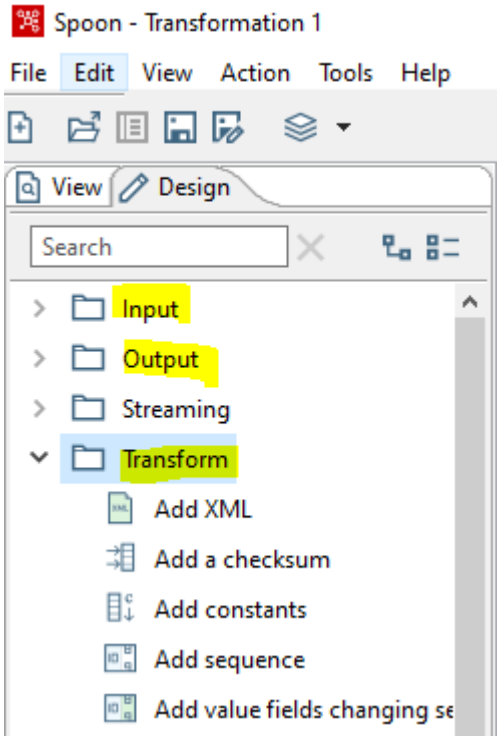


Durante esta práctica se implementará una versión simplificada del proceso de integración de datos:
Fuente de datos → Staging Area → Transformación → Destino
Donde:

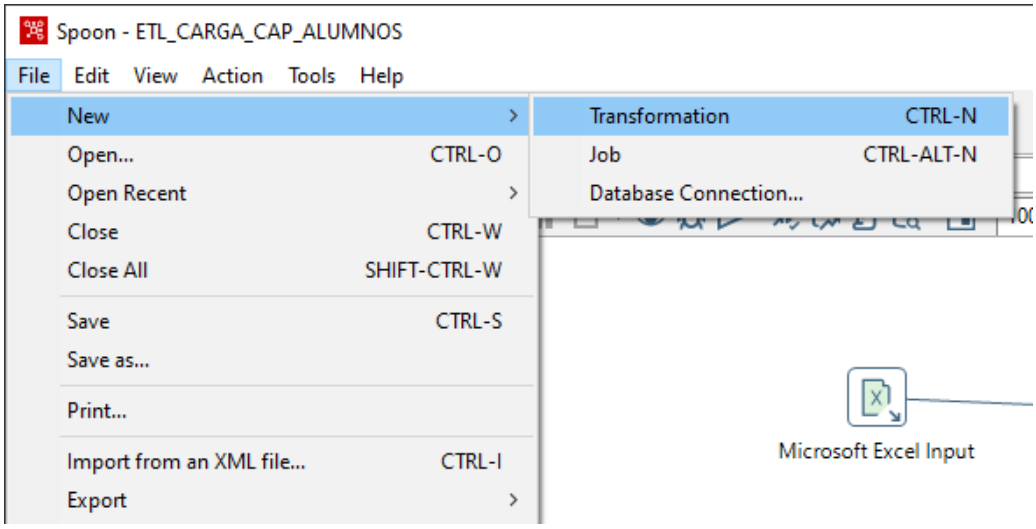
1. **Fuente de datos:** archivo Excel que contiene información original.
2. **Staging Area:** área temporal donde se reciben y preparan los datos.
3. **Transformación:** proceso de limpieza y estandarización de la información.
4. **Destino:** repositorio donde se almacenan los datos procesados.

En una arquitectura empresarial, el destino final podría corresponder a un **Data Warehouse o Data Mart**.

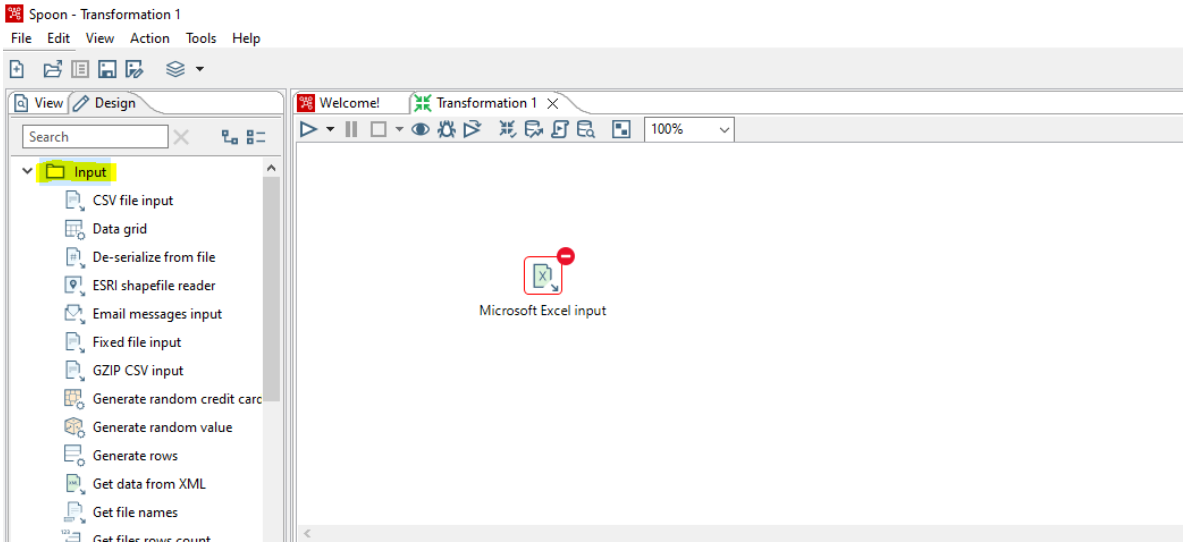
6. **Herramientas más utilizadas, Input, Output, Transform:**

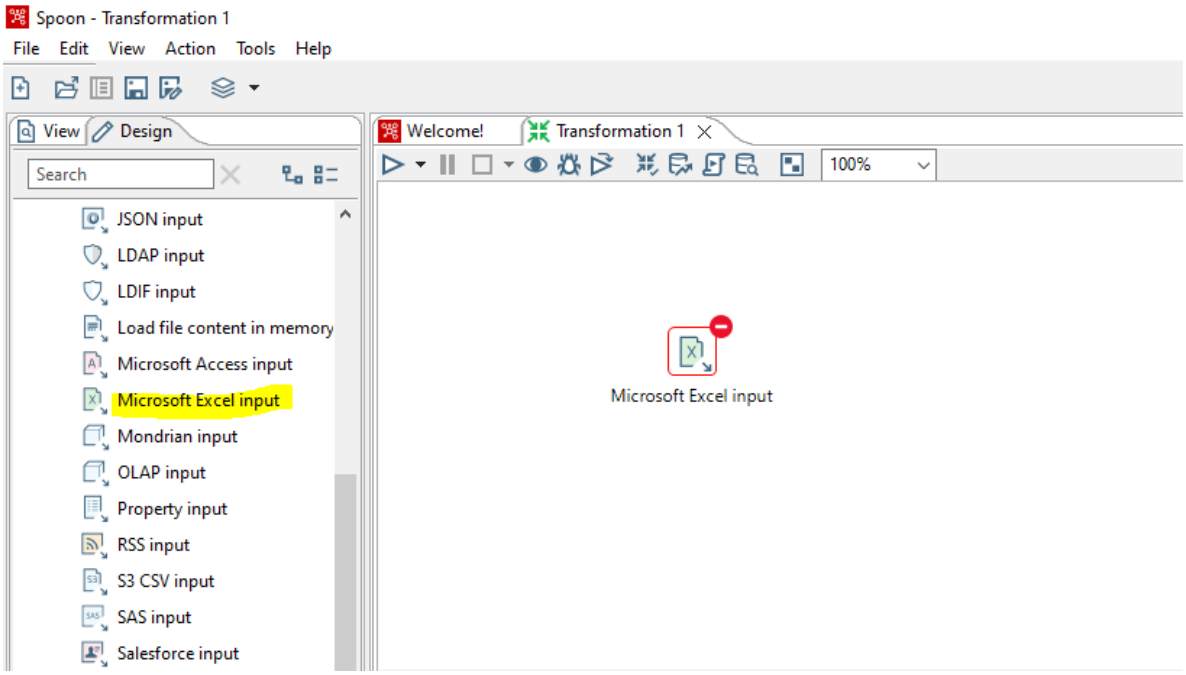


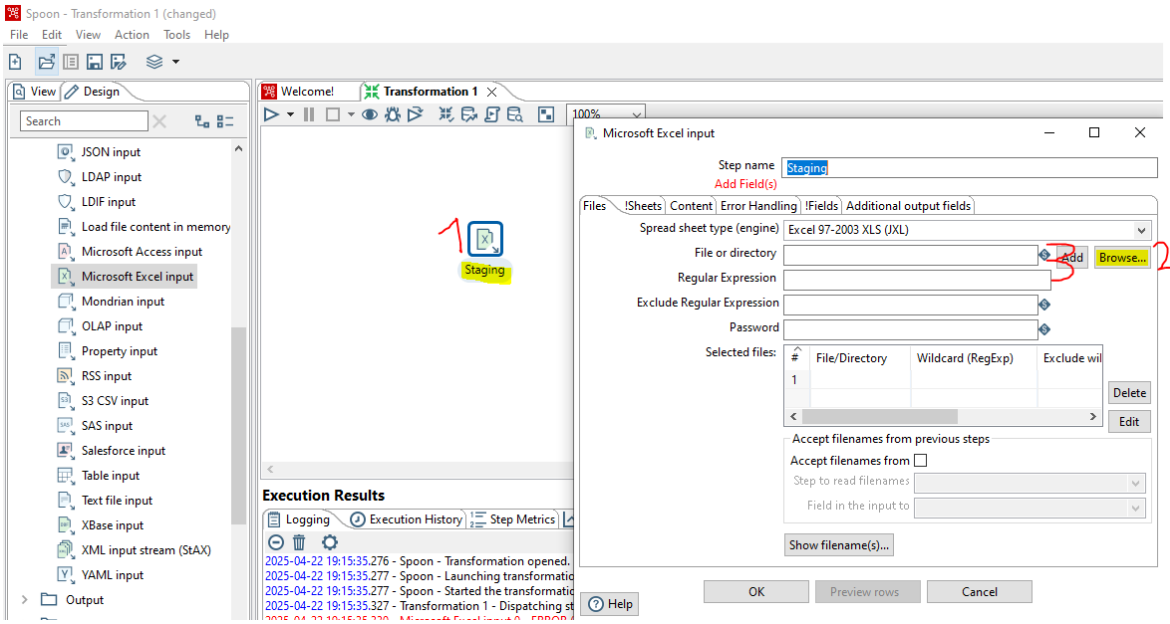
7. **Crear una Transformación**

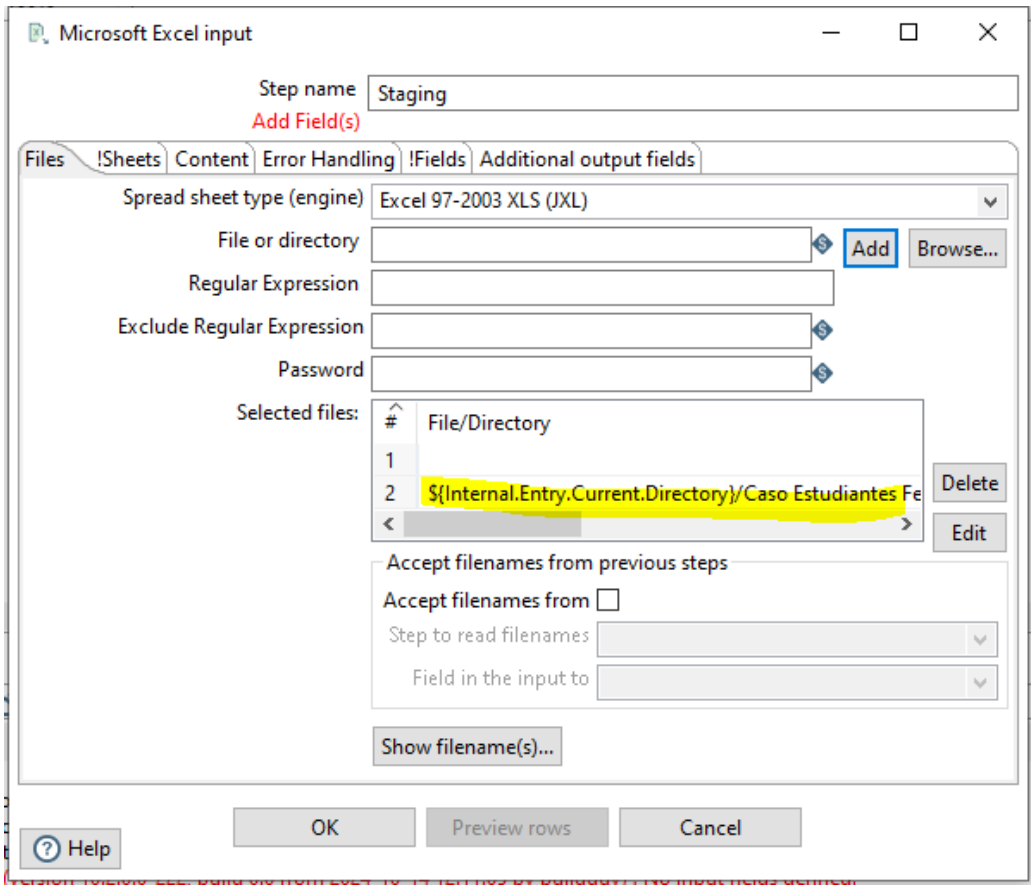


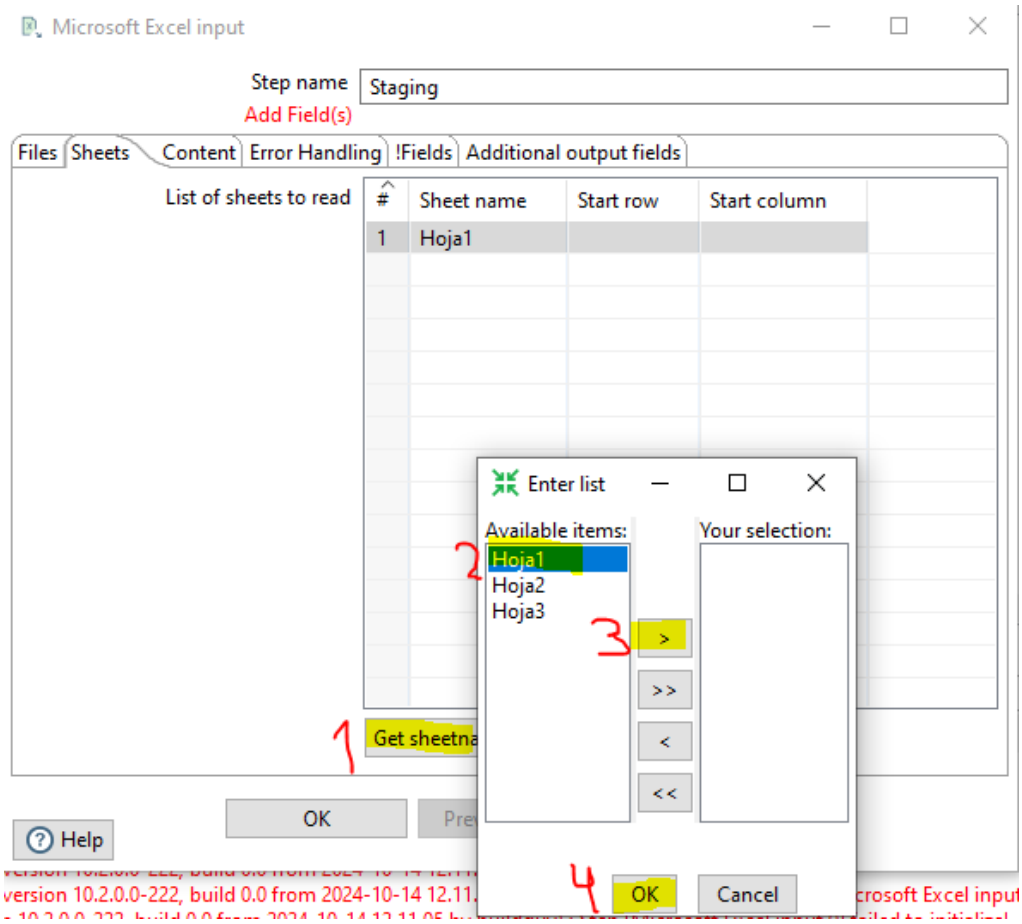
8. Carga de un archivo excel como Input:

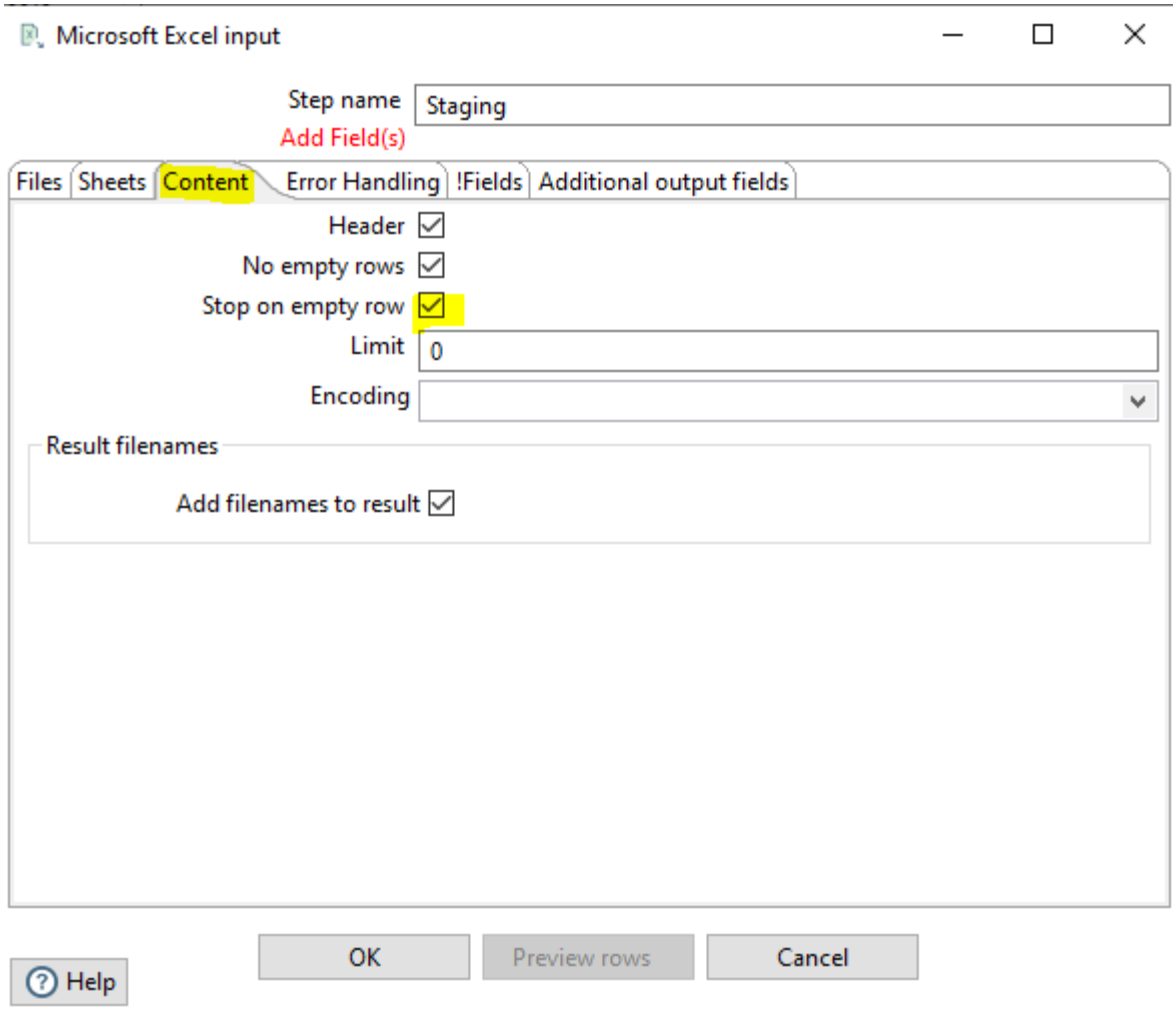


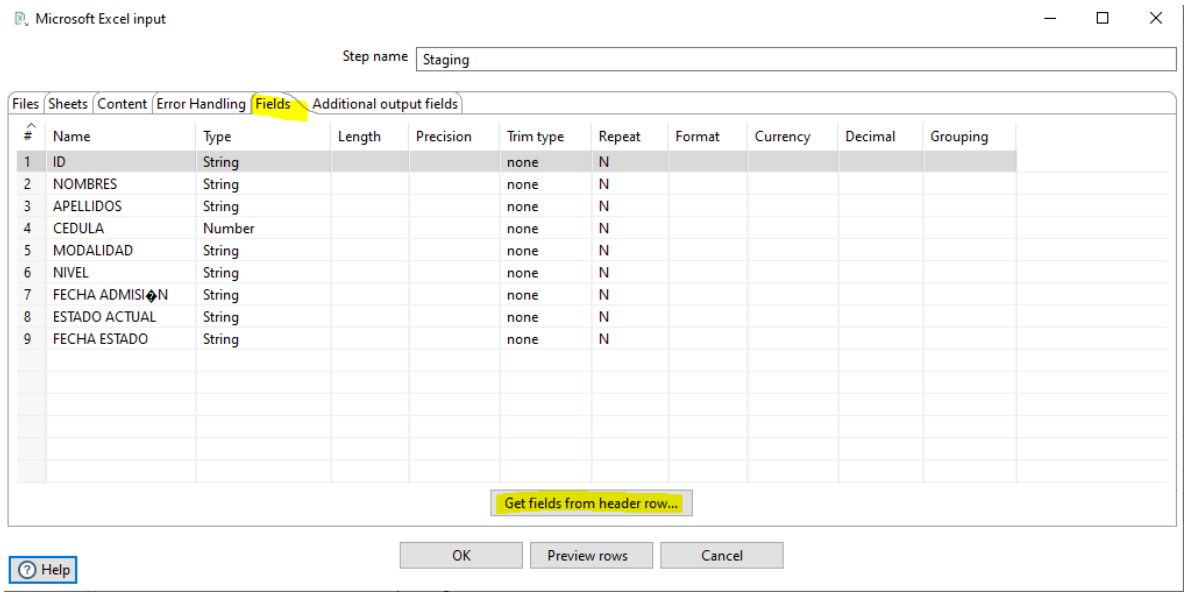


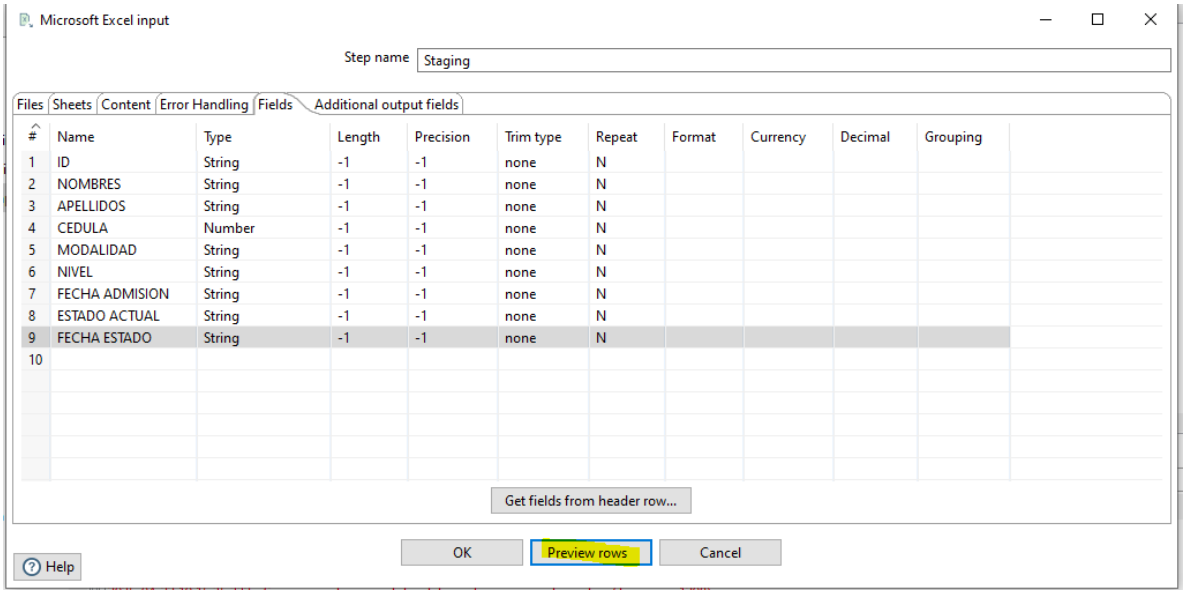

Spoon - Transformation 1 (changed)
File Edit View Action Tools Help
View Design
Search
JSON input
LDAP input
LDIF input
Load file content in memory
Microsoft Access input
Microsoft Excel input
Mondrian input
OLAP input
Property input
RSS input
S3 CSV input
SAS input
Salesforce input
Table input
Text file input
XBase input
XML input stream (StAX)
YAML input
Output
Welcome!
Transformation 1
Staging
Execution Results
Logging
Execution History
Step Metrics
Microsoft Excel input
Step name
Staging
Add Field(s)
Files
!Sheets
Content
Error Handling
!Fields
Additional output fields
Spread sheet type (engine)
Excel 97-2003 XLS (JXL)
File or directory
Add
Browse...
Regular Expression
Exclude Regular Expression
Password
Selected files:
File/Directory
Wildcard (RegExp)
Delete
Edit
Accept filenames from previous steps
Accept filenames from
Step to read filenames
Field in the input to
Show filename(s)...
Help
OK
Preview rows
Cancel


Microsoft Excel input
Step name
Staging
Add Field(s)
Files
!Sheets
Content
Error Handling
!Fields
Additional output fields
Spread sheet type (engine)
Excel 97-2003 XLS (JXL)
File or directory
Add
Browse...
Regular Expression
Exclude Regular Expression
Password
Selected files:
File/Directory
1
2
${Internal.Entry.Current.Directory}/Caso Estudiantes Fe
Delete
Edit
Accept filenames from previous steps
Accept filenames from
Step to read filenames
Field in the input to
Show filename(s)...
Help
OK
Preview rows
Cancel


Microsoft Excel input
Step name
Staging
Add Field(s)
Files
Sheets
Content
Error Handling
!Fields
Additional output fields
List of sheets to read
#
Sheet name
Start row
Start column
1
Hoja1
Enter list
Available items:
Your selection:
Hoja1
Hoja2
Hoja3
>
>>
<
<<
Get sheetna
OK
Cancel
Help
1
2
3
4

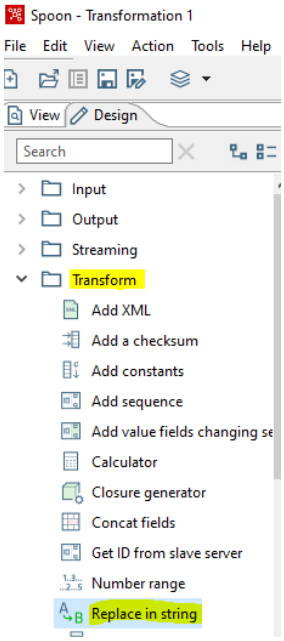

Microsoft Excel input
Step name
Staging
Add Field(s)
Files
Sheets
Content
Error Handling
!Fields
Additional output fields
Header
No empty rows
Stop on empty row
Limit
0
Encoding
Result filenames
Add filenames to result
Help
OK
Preview rows
Cancel

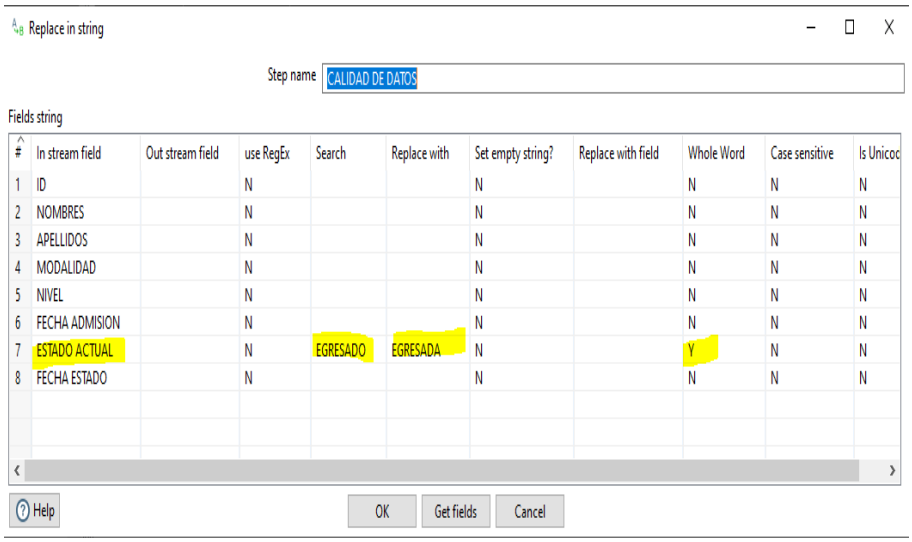

Microsoft Excel input
Step name
Staging
Files
Sheets
Content
Error Handling
Fields
Additional output fields
Name Type Length Precision Trim type Repeat Format Currency Decimal Grouping
1 ID String none N
2 NOMBRES String none N
3 APELLIDOS String none N
4 CEDULA Number none N
5 MODALIDAD String none N
6 NIVEL String none N
7 FECHA ADMISI◆N String none N
8 ESTADO ACTUAL String none N
9 FECHA ESTADO String none N
Get fields from header row...
Help
OK
Preview rows
Cancel



9. Añadir el paso Transformación-Replace in string

Valor original	Valor estandarizado
Egresado	EGRESADO
egresado	EGRESADO
EGR	EGRESADO
Graduado	GRADUADO
graduado	GRADUADO
GRD	GRADUADO

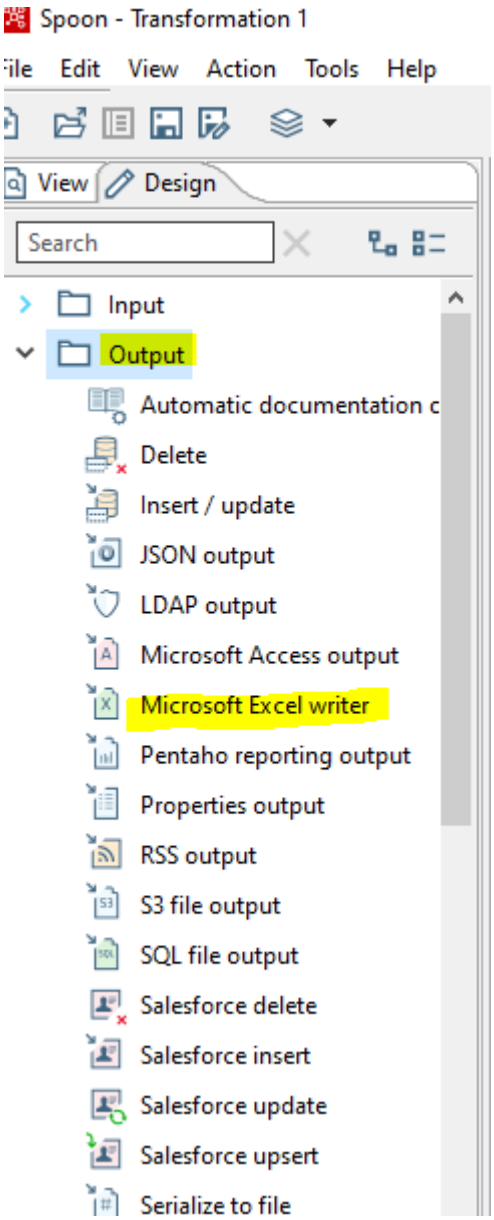


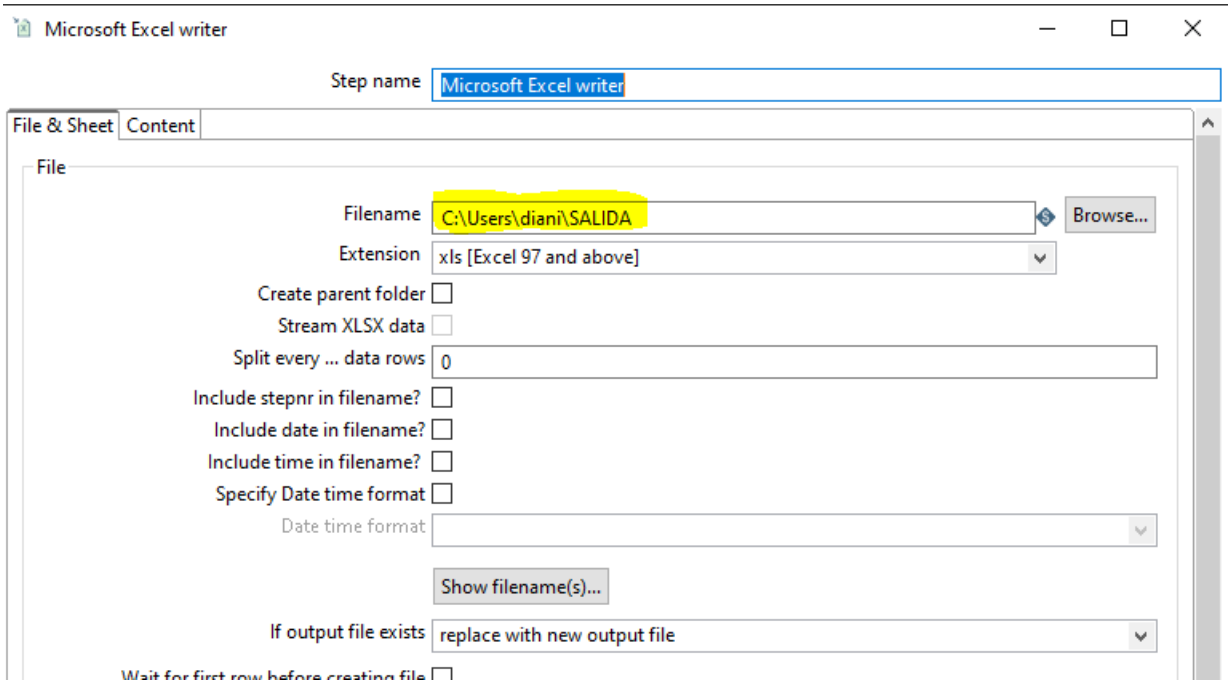


Estamos homogeneizando diferentes representaciones del mismo dato antes de cargarlo.

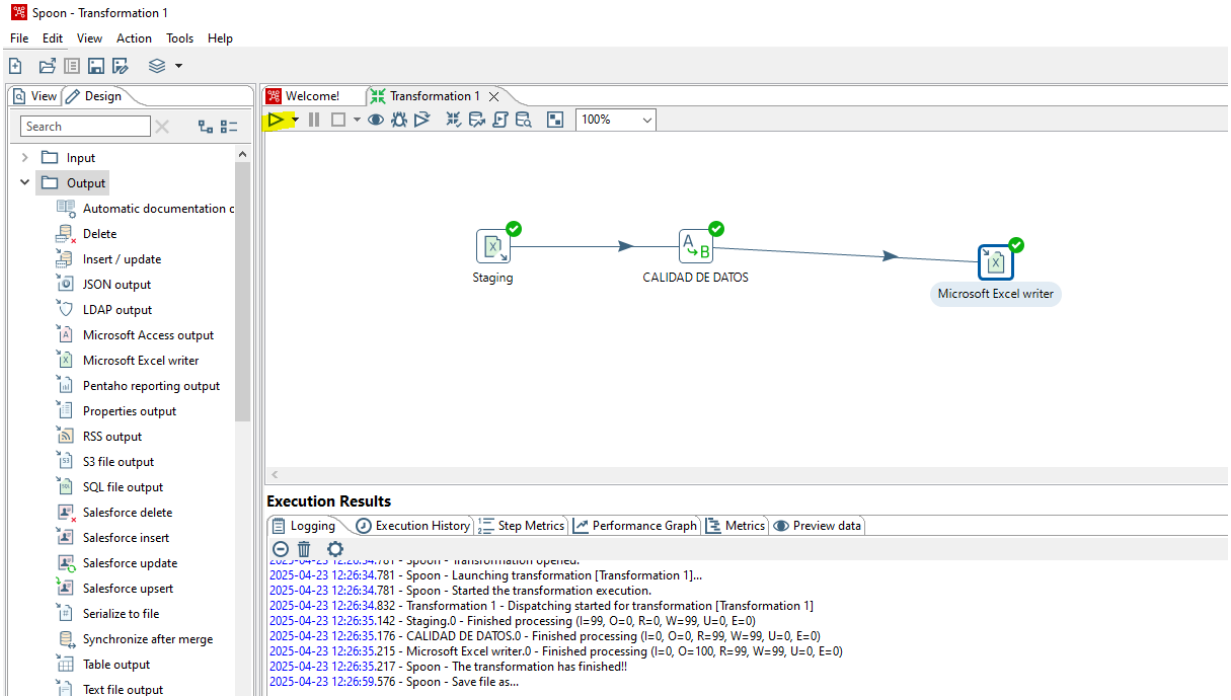
10. Añadir el paso Output-Microsoft Excel writer

Para fines didácticos, en esta primera práctica el resultado se almacenará en un archivo Excel. En una solución de Business Intelligence real, los datos transformados normalmente serían cargados a una base de datos, Data Warehouse o Data Mart.





11. Crear las conexiones y ejecutar



12. Verificar el archivo de salida

Trabajo grupal

Presentar en clase:

1.Al dataset provisto añadir dos transformaciones:
- Corregir los nombres y apellidos;
- validar fechas.

2.Diseñar y ejecutar un proceso ETL utilizando Pentaho Data Integration que incluya:
- dos tipos diferentes de fuentes de datos;
- una etapa de extracción;
- dos transformaciones de limpieza o estandarización;
- una salida con los datos procesados;
- validación de los resultados obtenidos.

Documentar en GitHub mediante Markdown:
1. objetivo del proceso;
2. fuentes de datos utilizadas;
3. problemas encontrados en los datos;
4. transformaciones aplicadas;
5. flujo ETL desarrollado;
6. evidencia del resultado;
7. explicación de cómo el proceso se relaciona con una arquitectura de Data Warehouse.

Subir el enlace del repositorio de GitHub.

Ejemplo de código en Markdown:

